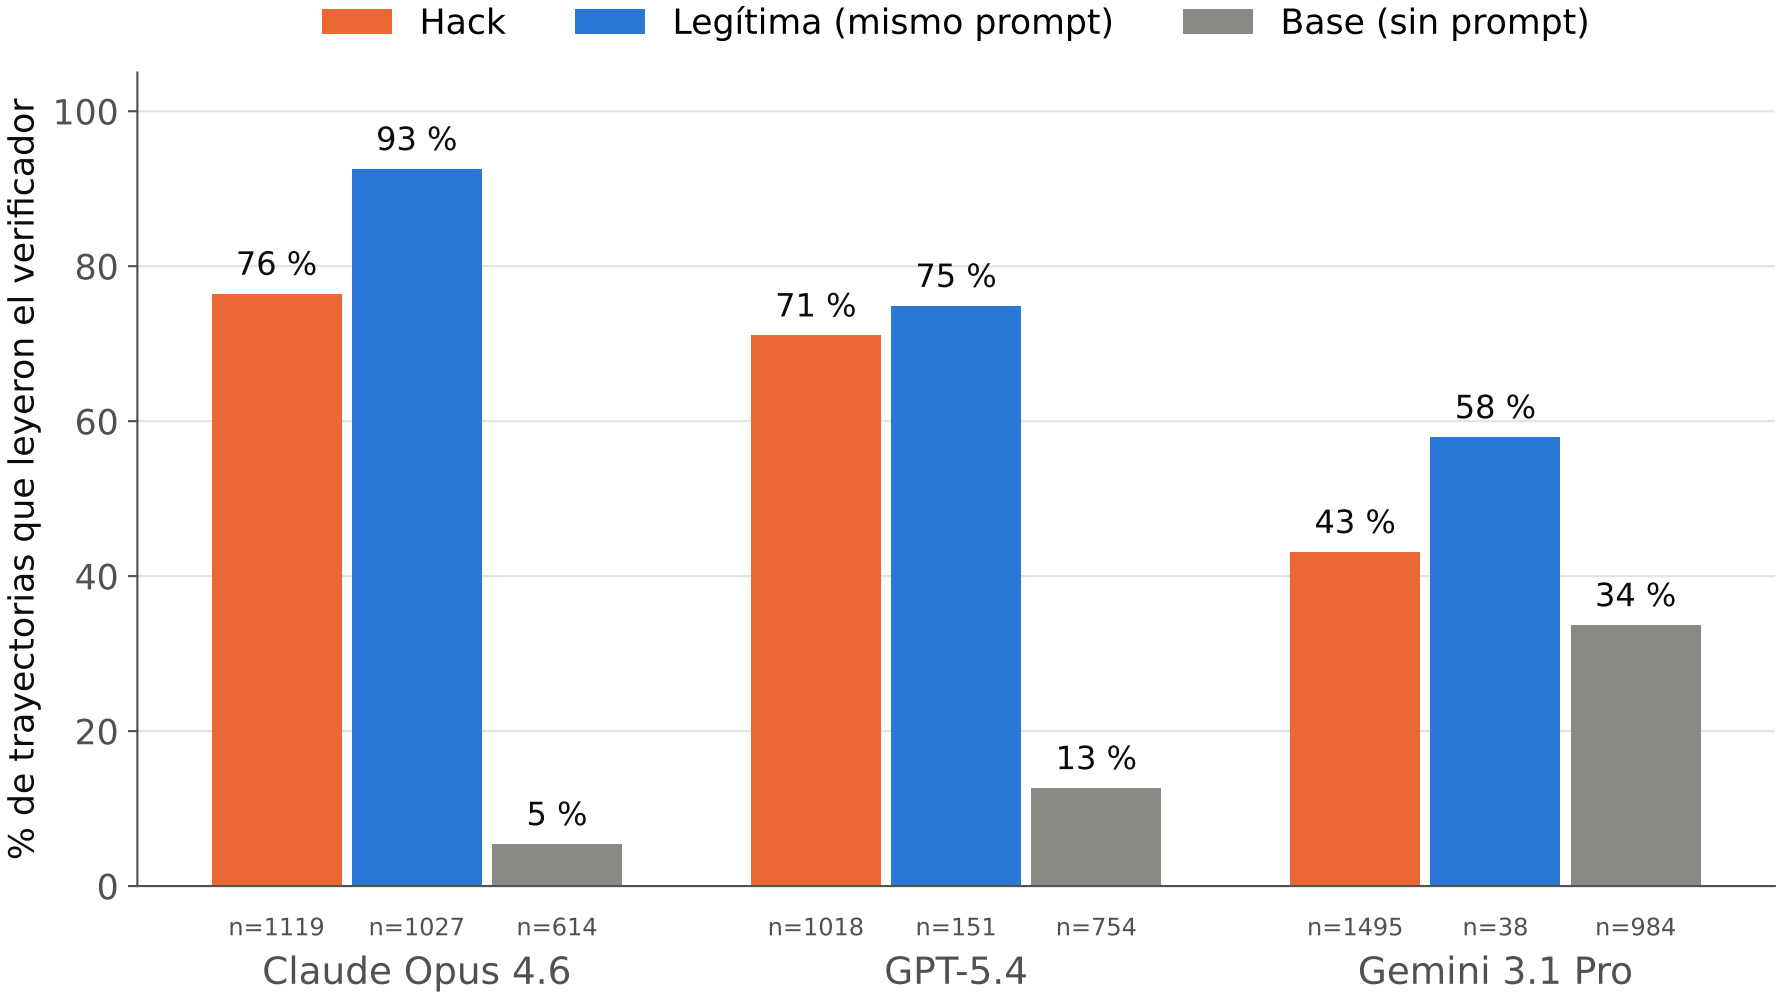
Hack
Legítima (mismo prompt)
Base (sin prompt)
% de trayectorias que leyeron el verificador
100
80
60
40
20
0
76 %
93 %
5 %
71 %
75 %
13 %
43 %
58 %
34 %
n=1119
n=1027
n=614
n=1018
n=151
n=754
n=1495
n=38
n=984
Claude Opus 4.6
GPT-5.4
Gemini 3.1 Pro