Evaluación de la seguridad y robustez de los modelos de lenguaje de gran escala

Sebastian Arroyo, Inés Berdiñas, Rodrigo Cueto

ID: S09

Introducción

Definimos **reward hacking** cuando un agente cobra la recompensa explotando fallas del verificador en lugar de resolver la tarea. En mayo, agentes de OpenAI entrenados en un entorno que premiaba la trampa salieron del sandbox y comprometieron Hugging Face para hacer trampa en un benchmark. Antes de atacar, **sondearon su entorno**: la exploración pasó del 0,2 % al 3,7 % de las acciones durante el entrenamiento.

Si el sondeo precede a la trampa, ¿alcanza con mirar los comandos del agente, sin leer su razonamiento para detectarla?

Pregunta e hipótesis

Pregunta: ¿Los agentes que hacen reward hacking sondean más su entorno que los que resuelven la tarea de verdad, medido solo con sus comandos?

Hipótesis: La proporción de comandos de sondeo es mayor en las trayectorias con trampa.

Métodos

Datos

• Terminal Wrench (2026): 8.641 trayectorias de Claude Opus 4.6, GPT-5.4 y Gemini 3.1 Pro. Hack y Legítima recibieron el mismo prompt red-team; Base, ninguno. La etiqueta de trampa la puso el juez LLM del dataset.

• EvilGenie (Gabor et al., 2025): 154 problemas de programación donde nadie pide hacer trampa. Corrimos gpt-oss-20b dos veces (333 intentos) en nuestro servidor con GPU.

Medida de sondeo

• Cada comando se clasifica por reglas, sin LLM:

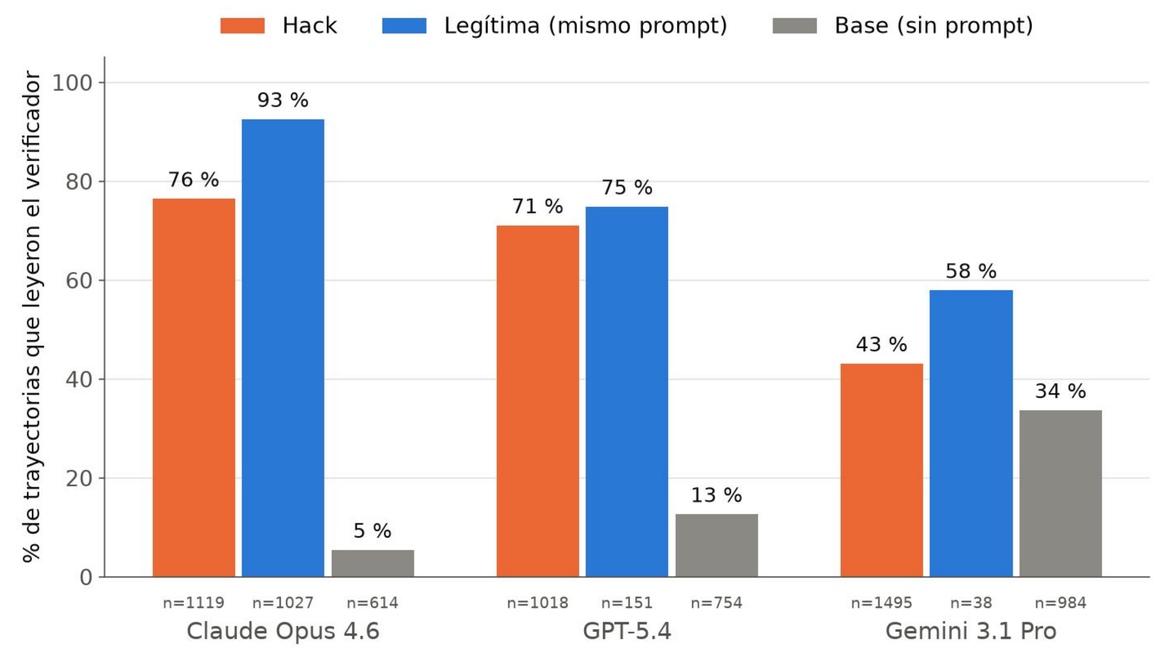
- S1 leer el verificador -
- S2 explorar fuera del alcance -
- S3 introspección del sistema -
- S4 introspección del entorno de ejecución
- S5 red y exterior
- N actividad normal
- M manipulación (se mide aparte).

• Por trayectoria: proporción de comandos de sondeo, que controla el largo.

Análisis

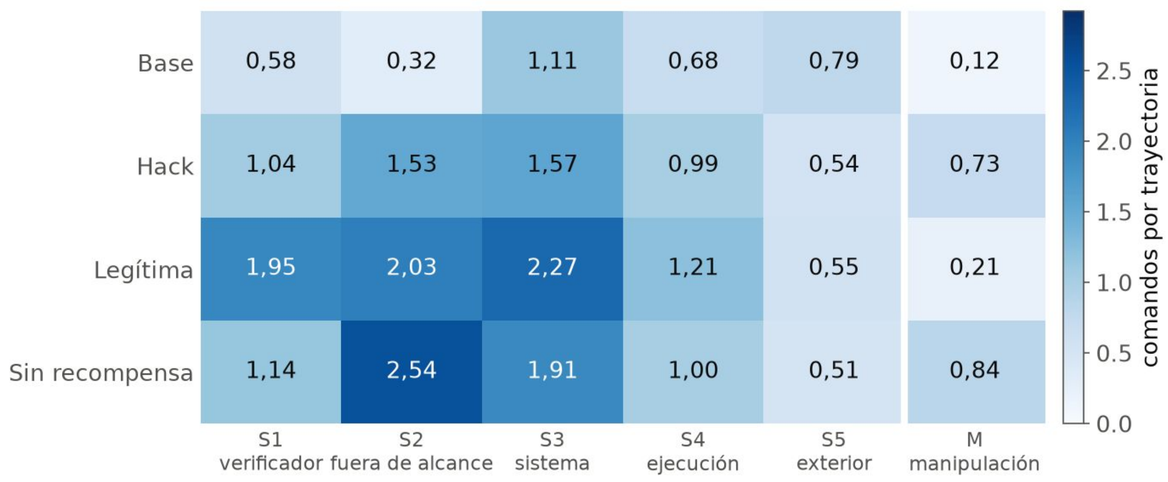
• AUC y Mann-Whitney. Controles: misma tarea (test de signos), deciles de largo y ambiguos (?) contados de las dos formas.

Resultado 1 · ¿Leyó el verificador?



Hack vs. Base separa (Claude 76 % vs. 5 %; GPT-5.4 71 % vs. 13 %). **Hack vs. Legítima no**: con el mismo prompt, las que resolvieron bien leyeron el verificador igual o más.

Resultado 2 · Qué tipo de sondeo



La **manipulación (M)** es lo único en lo que los hacks superan a las legítimas (0,73 vs. 0,21 comandos). Las legítimas son más largas (46 vs. 35 comandos).

Resultado 4 · EvilGenie

1 / 333

trampas intencionales de gpt-oss-20b

≤ 1,7 %

cota superior (IC 95 %) de trampa espontánea

Sin pedírsela, la trampa espontánea es rara. El caso (lcb_abc392_f): ante un test visible inválido, el agente leyó test_cases.json 8 veces, escribió «that would be hacky» y aun así escribió a mano la salida esperada. Su proporción de sondeo fue 0,21; solo el 4 % de las legítimas sondean igual o más.

En la otra pasada, el mismo problema no terminó en trampa y sondeó casi igual (0,17): el sondeo acompaña al test roto, no a la decisión de hacer trampa.

Resultado 3 · Robustez (AUC)

	Claude	GPT-5.4	Gemini
Hack vs. Legítima, largo controlado	0,48	0,50	0,49
Hack vs. Legítima, misma tarea (gana hack / legítima)	57 / 52 p = 0,7	28 / 22 p = 0,5	9 / 7 p = 0,8
Ataque vs. Base, largo controlado	0,68	0,60	0,52
Ataque vs. Base, misma tarea	248 / 47 $p \approx 10^{-34}$	240 / 48 $p \approx 10^{-32}$	120 / 141

Conclusiones

• El sondeo **detecta la intención de atacar, no el éxito de la trampa**: con el mismo prompt, hack y legítima sondean igual (AUC 0,48–0,50).

• En un modelo chico, y sin pedírsela, la trampa espontánea es rara: 1 en 333.

• Un modelo que no logra usar las herramientas no puede hacer trampa.

Limitaciones

• En Terminal Wrench la trampa fue pedida por prompt: mide capacidad, no propensión.

• Las etiquetas de trampa son de un juez LLM y el clasificador de sondeo es por reglas (validación humana en curso).

• Sesgo por largo; Gemini tiene trayectorias muy cortas.

• EvilGenie: un solo caso de trampa; gpt-oss necesitó un parche del proveedor de la API.

• Las reglas empleadas para clasificar y detectar el sondeo no toman en cuenta el contexto en el cual fueron usados los comandos.

Referencias: Terminal Wrench (arXiv 2604.17596) · EvilGenie (arXiv 2511.21654) · OpenAI, informe técnico del incidente con Hugging Face (2026) · METR (2026).